

# Aceleração Global Dev #4 everis

**Explorando o poder do NoSQL com Apache Cassandra  
e Apache HBase**

---

Valdir Sevaio  
Expert Data Analyst

# Objetivos da Aula

- 1.** Conceito NoSQL e porquê utilizamos no Big Data?
- 2.** Introdução Apache Hbase e Apache Cassandra
- 3.** Comandos (Definição de dados, Manipulação e Segurança)
- 4.** Cenários de utilização NoSQL no BigData
- 5.** Operações de carga massiva
- 6.** Integrações NoSQL com Ambiente Hadoop
- 7.** Próximos passos

# Requisitos Básicos

- ✓ VM disponibilizada pela Everis

# 1. Conceito NoSQL e porquê utilizamos no Big Data?

NoSQL com Hbase e Cassandra

# Introdução NoSQL

Significados:

NoSQL = “No SQL”, “Não SQL” ou “Não Relacional”

NoSQL = “Not Only SQL”

Termo genérico para representar os bancos de dados não relacionais.

O NoSQL emergiu como uma alternativa de banco de dados não relacionado, normalmente evitando operações de “join”, é distribuído, open-source, escalável na horizontal, livre de modelagens ou schema (não é necessário fixar modelos para as tabelas), suporta replicação, acesso via API de operações e eventualmente consistente.



# Relacional vs NoSQL


Quando considerar NoSQL	Quando considerar Relacional
Carga de trabalho de alto volume que exigem grande escala	Carga de trabalho é consistente e requer escala média para grande
Carga de trabalho não exigem garantias do ACID	Garantias de ACID são necessárias
Os dados são dinâmicos e frequentemente alterados	Dados são previsíveis e altamente estruturados
Os dados podem ser expressos sem relações (joins)	Os dados são expressos de maneira relacional
Alto velocidade de gravação e a segurança de gravação não é crítica	A garantia de gravação é um requisito
Consulta de dados é simples e tende a ser simples	Consultas e relatórios complexos
Dados exigem uma ampla distribuição geográfica	Usuários são mais centralizados




# Tipos de NoSQL

## SQL

### Relational




### Analytical (OLAP)



## NoSQL

### Key-Value



### Column-Family



### Graph



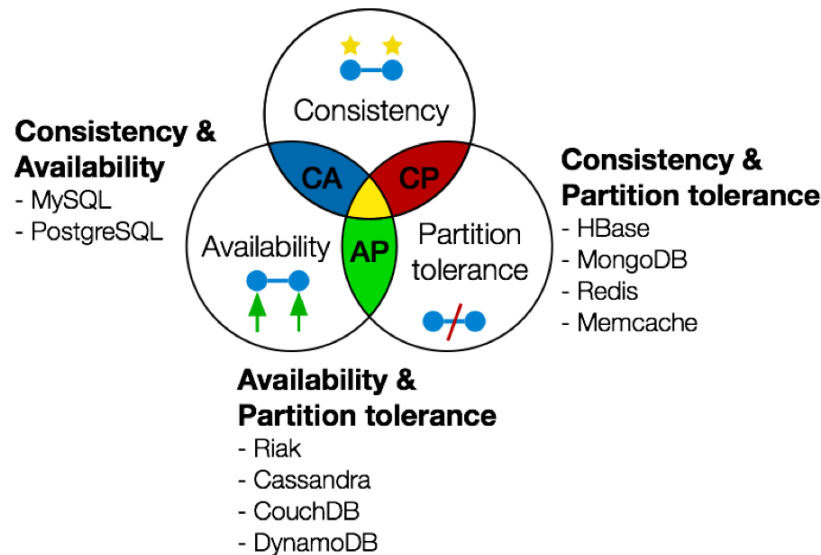
### Document



# Teorema de CAP

O teorema CAP ou teorema de Brewer indica que o armazenamento de dados distribuídos só podem atender dois dos três atributos: **Consistência, Disponibilidade, Partição Tolerante a Falhas**.

Tanto Hadoop e HBase atendem CP, porque possuem um ponto de falha que é respectivamente o NamedNode e HMaster que não possuem redundância dos dados dos próprios serviços para todos os nós do cluster.





# Por quê NoSQL no Big data?

## Limitações do Hadoop

- Hadoop (MapReduce) pode executar apenas processamento batch e os dados são acessados de forma sequencial, isso significa que é necessário percorrer todo o conjunto de arquivos (*scan search*) mesmo para os jobs mais simples.

## Cenário

- Um grande conjunto de dados (*dataset*) quando processado com um outro conjunto de dados, ambos serão processados de maneira sequencial, nesse momento **uma nova solução é necessária para acessar qualquer ponto do *dataset* (linhas) e que leve um tempo menor para retornar.**
- Aplicações como HBase, Cassandra, Dynamo e MongoDB, etc, são banco dados que armazenam grandes quantidade de dados e os acessos à esses dados são realizados de forma **aleatória em termos de posição do registro e do tempo.**

# 2. Introdução HBase e Cassandra

NoSQL com Hbase e Cassandra

# O que é o Apache Hbase?

HBase é um banco de dados **distribuído** e **orientado a colunas** (Column Family ou Wide Column).

Uma definição mais técnica:

O armazenamento do HBase é um esparsos, distribuído, persistente, multidimensional e ordenado **Map**.

As maiores desvantagens do Hbase é não ter uma linguagem própria de SQL, não suportar índices em colunas fora do rowkey e não suportar tabelas secundárias de índices.

A maior vantagem é a facilidade e integração com o ecossistemas Hadoop.

## Cont. O que é o Apache Hbase?

**Map** é indexado por uma linha chave (**row key**), coluna chave (**column key**), e um coluna timestamp.

Cada valor no **Map** é interpretado como um vetor de bytes (**array of bytes**).

O **array of bytes** nos permite gravar portanto qualquer informação se for necessário, inclusive documentos, arquivos JSON, CSV, etc.

# Cont. O que é o Apache Hbase?

Portanto podemos entender que o núcleo de dados do HBase é um Map.

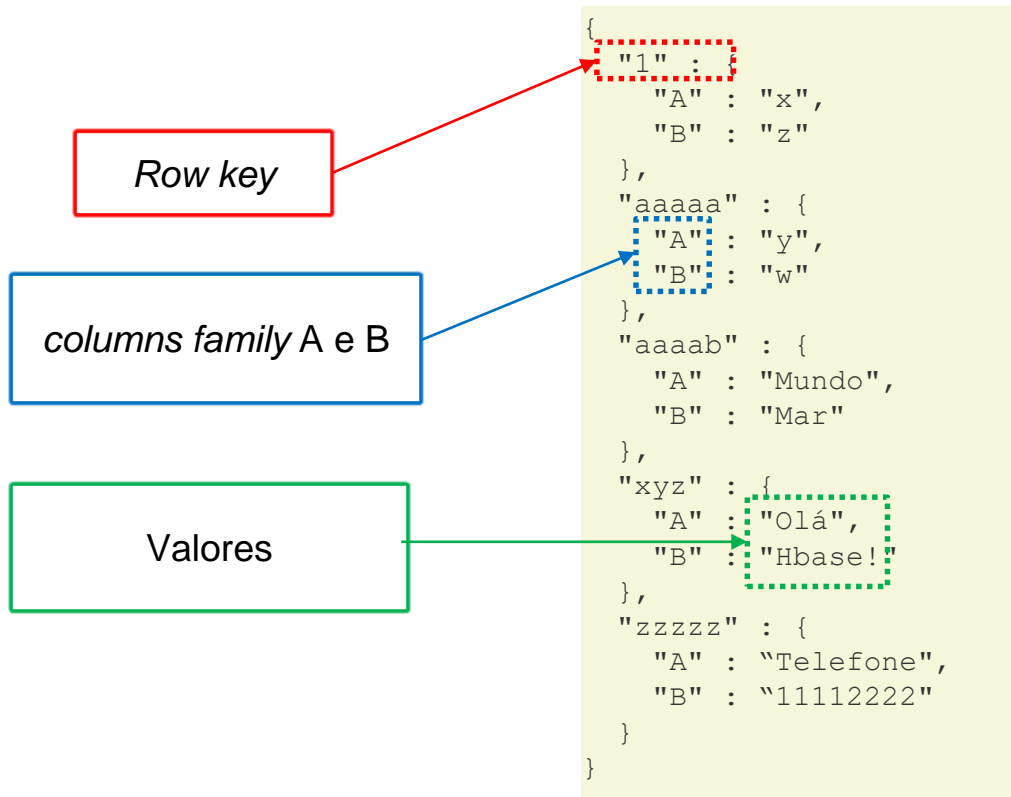
Na maioria das linguagens de programação essa abstração de estrutura de dados existe e pode ser representada como um conjunto de chaves e conjunto de valores. **Cada chave é associada à um valor.**

```
{  
  "zzzzzz" : "Olá",  
  "xyz" : "hello",  
  "aaaab" : "world Hbase!",  
  "1" : "x",  
  "aaaaa" : "y"  
}
```

# Cont. O que é o Apache Hbase?

## Multidimensional e Ordenado

Esquecendo o conceito tradicional de linhas e colunas do mundo relacional, pense no multidimensional como um **Map** que contém **Maps**.

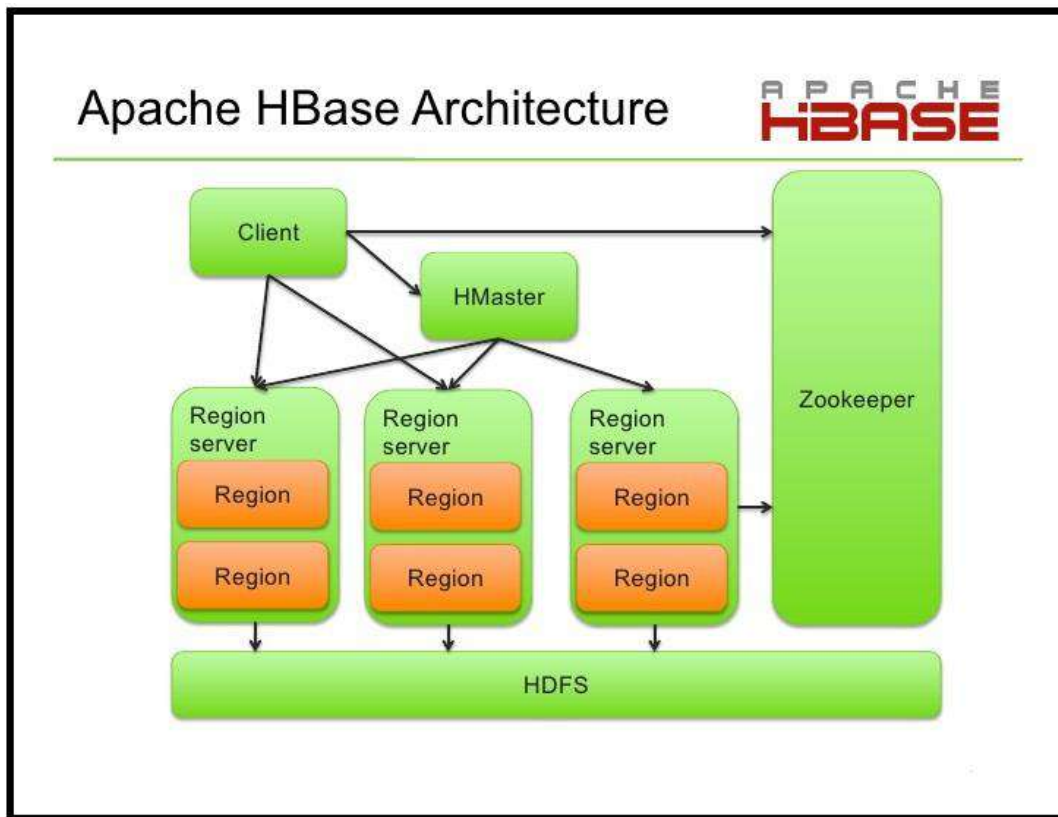


# Cont. O que é o Apache Hbase?

Representação Tabular dos dados no HBase.

COLUMN FAMILIES				
Row key	personal data		professional data	
empid	name	city	designation	salary
1	raju	hyderabad	manager	50,000
2	ravi	chennai	sr.engineer	30,000
3	rajesh	delhi	jr.engineer	25,000

# Arquitetura do HBase





# Cont. Arquitetura HBase

## HBase Client

Responsável por encontrar o RegionServers que estão atendendo as linhas em particular que estão sendo utilizadas, para isso é consultado uma base de dados de metadados interna do Hbase, **hbase:meta** que fica no Zookeeper.

Depois de localizado o RegionServer, o client se comunica para solicitar requisição de leitura/gravação do registro, isso até versão 2.x.y.

Apartir da versão 3.x.y. o HMaster controla as requisições leitura/gravação.

Caso ocorra erro na comunicação com o RegionServer por alguma falha será atribuído pelo load balancer do HMaster um novo RegionServer.

# Cont. Arquitetura HBase

## HMaster

Responsável por monitorar todas as instâncias de RegionServer no cluster. É meio para todas as solicitações de mudanças de metadados.

Em um ambiente distribuído de produção esse serviço é executado no NamedNode do Hadoop.

É possível ter vários nós de um ambiente clusterizado atuar como master, porém só um pode ficar ativo, o restante fica passivo, caso ocorra alguma falha no master principal.

# Cont. Arquitetura HBase

## RegionServer

Responsável por monitorar todas as instâncias de RegionServer no cluster. É meio para todas as solicitações de mudanças de metadados.

Em um ambiente distribuído de produção esse serviço é executado no NamedNode do Hadoop.

É possível ter vários nós de um ambiente clusterizado atuar como master, porém só um pode ficar ativo, o restante fica passivo, caso ocorra alguma falha no master principal.

# Cont. Arquitetura HBase

## Regions

Representam os elementos básicos de disponibilidade e distribuição das tabelas e incluem o armazenamento de cada column family.

### Hierarquia dos Objetos no HBase

- Table (Tabela HBase)

  - Region (Regiões da tabela)

    - Store (Unidade de armazenamento por ColumnFamily para cada região da tabela)

      - MemStore (MemStore para cada armazenamento em cada região da tabela)

      - StoreFile (StoreFiles para cada armazenamento em cada região da tabela)

        - Block (Arquivos que servem como blocos dentro do StoreFile dentro do armazenamento em cada região de uma tabela)

# Cont. Arquitetura HBase

## Apache Zookeeper

O tipo de instalação distribuída do Hbase é necessário que o Apache Zookeeper esteja funcionando no cluster.

O Apache Zookeeper é o responsável por dar visibilidade a todos os nós de serviços do HBase de quem é o master atual, são os servidores que atendem ao papel RegionServers, Region. Toda configuração que é padrão para cada um dos papéis são armazenados no Zookeeper, portanto ele tem um papel fundamental de manter sincronizado toda a parametrização em comum para todos os nós.

O cliente HBase se comunica com os RegionServer através do Zookeeper.

# Cont. Arquitetura HBase

## Apache HDFS

É o sistema de arquivos do ecossistema do Hadoop. Cada arquivo está armazenado em múltiplos blocos e mantém tolerância a falhas, os blocos são replicados pelos cluster Hadoop.

HDFS é utilizado pelo componentes do HBase.

Os arquivos gerenciados pelo HBase são criados dentro do HDFS.

### HBASE

### HDFS com Hive/MR

Baixa latência nas operações	Alta latência nas operações
Acesso a leitura e gravação aleatória	Grava única e leitura muita vezes
Acessado através de comandos shell, cliente API em Java, REST, Avro ou Thrift	Acessado primeiramente através dos Jobs do MR(Map Reduce)

# O que é o Apache Cassandra?

O Cassandra é um banco de dados **distribuído** e **orientado a colunas** (Wide Column).



Diferente do Hbase, os dados armazenados são tipados e há conceitos mais complexos de modelagem como chave primária composta, partition key e cluster key.

O Cassandra possui a linguagem SQL (**CQL**) contém semelhante com SQL ANSI porém algumas operações não são suportadas / recomendadas, por exemplo: joins, alguns tipos de agrupamentos e tipos de filtros.

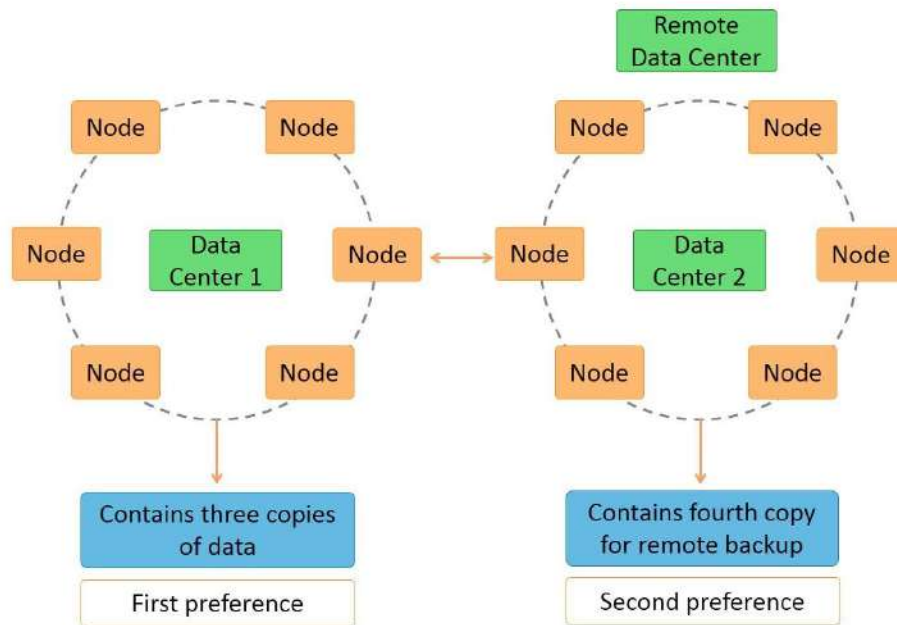
A recomendação para modelagem de dados no Cassandra, é pensar em quais query devem ser consumidas e agregar as informações em uma determinada tabela.

Uma grande diferença para o Hbase, é que o **Cassandra suporta tabela secundárias de índices e permite filtros em colunas fora da primary key.**

# Arquitetura do Cassandra

A característica principal do Cassandra é armazenar em múltiplos nós sem nenhum ponto de falha.

Conexão entre os nós é realizada de ponto a ponto, utilizando um protocolo chamado **Gossip**.





# Componentes do Cassandra

## Node

Nó responsável por armazenar os dados, é um componente básico da Arquitetura.

## Data Center

Representa uma coleção de nós.

## Cluster

Representa a coleção de vários Data Centers.

## Commit Log


Cada operação é escrita no log de commit. Esse log é utilizado para recuperação em caso de incidents graves.

## Mem-table

Depois que o dado é escrito no log de commit, o dado é escrito no Mem-table. O dado nessa localidade é temporário.

## SSTable

Quando o Mem-Table atingiu um limite, o dado é gravado no disco no SSTABLE.



# 3. Comandos gerais

NoSQL com Hbase e Cassandra

# Comandos no HBase

## **hbase shell**

No console do HBase é possível utilizar todos os comandos de manipulação de informação e comandos gerais.

Atualmente o HBase até a versão 3.x.y não suporta uma query de consulta (SQL).

Os comandos mais básicos de manipulação das informação são: put, get, scan, drop, disable, etc.

# Cont.Comandos no HBase

## **hbase shell**

No console do HBase é possível utilizar todos os comandos de manipulação de informação e comandos gerais.

Atualmente o HBase até a versão 3.x.y não suporta uma query de consulta (SQL).

Os comandos mais básicos de manipulação das informação são: put, get, scan, drop, disable, etc.

# Cont.Comandos no HBase

## **status**

Comando dá detalhes sobre o sistema como o número de servidores presente, quantidade de servidores ativos, média de carga, quantidade de Stored ativos, é possível passar qualquer parâmetro dependendo em qual detalhe seja necessário saber sobre o sistema.

Variações

**status 'simple'**

**status 'summary'**

**status 'detailed'**

# Cont.Comandos no HBase

## **version**

Exibe a versão do HBase.

## **table\_help**

Comando que auxilia como utilizar comandos que se referenciam a uma tabela.  
É possível pegar a referencia de uma tabela cria e utilizar como variável para próximas operações.

# Cont.Comandos no HBase

Os comandos abaixo são utilizados para operar as tabelas no HBase.

**create** – Cria uma tabela.

**list** – Lista todas as tabelas no HBase independente do namespace.

**disable** – Desabilita uma tabela.

**is\_disabled** – Checa se uma tabela está desabilitada.

**enable** – Habilita uma tabela.

**is\_enabled** – Checa se uma tabela está habilitada.

**describe** – Exibe informações de definição de uma tabela.

**alter** – Realiza alterações em uma tabela.

**exists** – Verifica se uma tabela existe.

**drop** – Exclui um tabela do HBase.

**drop\_all** – Exclue todas as que se aplicam a um padrão de nomes via regra de Regex.

# Cont.Comandos no HBase

## CREATE\_NAMESPACE

Permite criar uma namespace no HBase.

Sintaxe:

```
create_namespace '<namespace>' {PROPRIEDADES}
```

Exemplo:

```
create_namespace 'empresa'
```



# Cont.Comandos no HBase

## CREATE

Permite criar uma tabela no HBase.

Sintaxe:

```
create '[<namespace>]:<nome tabela>', '<nome da column family>' {PROPRIEDADES}
```

Exemplo:

Imagine uma tabela de funcionarios

Row Key	Dados Pessoais	Dados Profissional

# Cont.Comandos no HBase

## Exemplo criação da tabela de funcionários

Comando:

```
create 'funcionario', 'pessoais', 'profissionais'
```

```
create 'funcionario', {NAME=>'pessoais', VERSIONS=>5}, {NAME=> 'profissionais',  
VERSIONS =>4}
```

Liste todas as tabelas

### **list**

Com o comando list é possível visualizar todas as tabelas presentes e criados no HBase.

É possível passar expressões regulares para realizar buscas mais personalizadas.

# Cont.Comandos no HBase

## DESCRIBE

O comando exibe informações sobre as column families presentes na tabela mencionada, também traz informações sobre os filtros associados, versões, se a tabela está em memória, etc.

### Sintaxe:

describe '<nome da tabela>'

### Comando:

describe 'funcionario'

# Cont.Comandos no HBase

## DISABLE

Desabilita a tabela mencionada, caso seja necessário que uma tabela seja deletada ou excluída, primeiro é necessário desabilita-la.

Após desabilitada ainda é possível lista-la (list) em conjunto com as demais tabelas e checar sua existência com comando exists, porém não é possível mais escanear (scan).

### Sintaxe:

disable '<nome da tabela>'

### Comando:

disable 'funcionario'

# Cont.Comandos no HBase

## DISABLE\_ALL

Desabilita as tabelas que atendem dentro do critério de expressão regular.

Para evitar interrupções importantes esse comando tem uma confirmação manual (Sim ou Não) antes de efetivar a desabilitação.

### Sintaxe:

```
disable_all '<prefixo da tabela>.*'
```

### Comando:

```
disable_all 'func.*'
```

# Cont.Comandos no HBase

## ENABLE

Habilita a tabela mencionada no comando. Se a tabela está desabilitada no primeiro momento e não foi deletada ou excluída, e desejamos reutilizar a tabela, então primeiro nos precisamos habilita-la novamente.

### Sintaxe:

```
enable '<nome da tabela>'
```

### Comando:

```
enable 'funcionario'
```

# Cont.Comandos no HBase

## DROP

Para deletar ou dropar uma tabela presente no HBase, primeiro é necessário desabilitá-la com o comando disable.

Sintaxe:

```
drop '<nome da tabela>'
```

Comando:

```
drop 'funcionario'
```

# Cont.Comandos no HBase

## DROP\_ALL

Esse comando excluirá todas as tabelas que estiverem com o nome dentro da regra da expressão regular.

Todas as tabelas que serão excluídas, precisam estar na situação de desabilitadas, portanto ter passado pelo comando `disable_all`.

### Sintaxe:

```
drop_all '<expressão regular>'
```

### Comando:

```
drop_all 'func.*'
```



# Cont.Comandos no HBase

## IS\_ENABLED

Esse comando só verificará se a tabela está habilitada ou não. Caso esteja desabilitada é necessário acionar o outro comando enable.

### Sintaxe:

```
is_enabled '<nome da tabela>'
```

### Comando:

```
is_enabled 'funcionario'
```

# Cont.Comandos no HBase

**ALTER** (Acrescentando column family e limitando versões da coluna)

Esse comando alterará a definição (schema) da família de colunas (column family) de uma tabela especificada.

Alterar uma única ou múltiplas column family.

Deletar column family

Diversas operações são permitidas utilizando atributos específicos de definição de uma tabela.

Sintaxe:

```
alter '<nome da tabela>', NAME=><column familyname>, VERSIONS => 5
```

Exemplo comando abaixo para limitar armazenamento até 5 versões da column family

```
alter 'funcionario', NAME => 'hobby', VERSIONS => 5
```

```
alter 'funcionario', 'delete'=>'hobby' (Para deletar)
```

# Cont.Comandos no HBase

## ALTER\_STATUS

Com esse comando é possível acompanhar com o status das alterações realizada de uma tabela para todos nós RegionServer.

### Sintaxe:

```
alter_status '<nome da tabela>'
```

### Comando:

```
alter_status 'funcionario'
```

# Cont.Comandos no HBase

Os comandos abaixo são utilizados para operar os dados no HBase.

**put** – Insere/Atualiza um valor em uma determinada célula de uma específica linha de uma tabela.

**get** – Consulta todo o conteúdo de uma linha ou célula em uma tabela.

**delete** – Exclui um valor de uma célula em uma tabela.

**deleteall** – Exclui todas as células de uma linha em específico.

**scan** – Varre toda a tabela retornando as dados contidos.

**count** – Conta e retorna o número de linhas em uma tabela.

**truncate** – Desabilita, exclui e recria uma tabela em específico.

**IMPORTANTE:** Todas as operações de CRUD lista acima estão disponíveis via API Java de utilização sob o pacote `org.apache.hadoop.hbase.client` com os objetos `Htable` `Put` e `Get`.

# Cont.Comandos no HBase

## PUT

Comando para inserir um determinado valor em uma célula na coluna ou linha.  
Também utilizado para atualizar um determinado valor de uma célula para um determinado rowKey e ColumnFamily:colname já existente.

### Sintaxe:

```
put '<nome da tabela>', '<rowkey>', '<columnfamily:colname>', '<valor>'
```

### Comando:

```
put 'funcionario', '1', 'pessoais:nome', 'Maria'  
put 'funcionario', '1', 'pessoais:cidade', 'São Paulo'  
put 'funcionario', '1', 'pessoais:cidade', 'Belo Horizonte'  
put 'funcionario', '2', 'profissionais:empresa', 'Everis'
```

*É acionado **upsert** da chave/valor.*

```
scan 'funcionario', {VERSIONS => 3}
```

# Cont.Comandos no HBase

## GET

Comando retorna um determinado valor em uma célula na coluna ou linha inteira do rowKey.

### Sintaxe:

```
get '<nome da tabela>', '<rowkey>', [parâmetros opcionais]
```

### Comando:

```
get 'funcionario', '1'
```

```
get 'funcionario', '1', {COLUMN => 'pessoais:cidade'}
```

Consultar todas as versões de uma column para um rowkey específico

```
get 'funcionario', '1', {COLUMN => 'pessoais:cidade', VERSIONS=> 3}
```

# Cont.Comandos no HBase

## COUNT

Comando recupera a quantidade de linhas de uma determinada tabela.  
O Intervalo de contagem de linhas pode ser especificado de forma opcional.  
A contagem de linhas é exibida a cada 1000 linhas.

### Sintaxe:

```
count '<nome da tabela>', CACHE => 1000
```

### Comando:

```
count 'funcionario', CACHE=> 1000
```

# Cont.Comandos no HBase

## DELETE

Comando remove um determinado valor em uma célula na coluna informadas, também possível remover todas as células de uma rowKey especificada.

### Sintaxe:

```
delete '<nome da tabela>', '<rowkey>', '<column name>'
delete '<nome da tabela>', '<rowkey>', '<column name>', '<timestamp>'
deleteall '<nome da tabela>', '<rowkey>'
```

### Comando:

```
delete 'funcionario', '1', 'pessoais:cidade'
delete 'funcionario', '1', 'pessoais:cidade', 129019101
deleteall 'funcionario', '1'
```



# Cont.Comandos no HBase

## SCAN

Comando remove um determinado valor em uma célula na coluna informadas, também possível remover todas as células de uma rowKey especificada.

### Sintaxe:

```
scan '<nome da tabela>', '[parâmetros opcionais]'
```

### Comando:

Exibe as ultimas versões de cada rowKey e respectivas colunas  
`scan 'funcionario'`

Exibe todas as últimas 10 versões de cada rowKey e respectivas colunas  
`scan 'funcionario', {RAW=>true, version=>10}`

# Cont.Comandos no HBase

## TRUNCATE

Comando remove todas as linhas e colunas presentes na tabela.  
Internamente o comando realizada a desabilitação da tabela, drop a tabela se ainda está presente, e recria.

### Sintaxe:

```
truncate '<nome da tabela>'
```

### Comando:

```
truncate 'funcionario'
```

# TTL – Registro temporário

## Colunas com propriedade TTL – Time To Live

É um mecanismo que permite configurar de forma opcional o tempo de permanência de registros em uma tabela ou especificamente de uma coluna.

**Configurável em segundos**, quantos tempo o registro ficará disponível para consulta.

**Os registros são deletados** após esse período.

Esse comportamento é feito para todas as versões de cada linha e também válido para quando o HBase é utilizado como intermediários no fluxo de dados ou seja para dados de transição.

A deleção do registro pode ocorrer também como versionamento da linha, como se fosse uma deleção lógica mas os dados vão continuar nas versões anteriores.

# TTL – Registro temporário

## Exemplo TTL – Time To Live

Criar uma tabela com registros que ficam 20 segundos na base.

```
create 'ttl_exemplo', { 'NAME' => 'cf', 'TTL' => 20 }
```

```
put 'ttl_exemplo', 'linha123', 'cf:desc', 'TTL Exemplo'
```

```
get 'ttl_exemplo', 'linha123', 'cf:desc'
```

Aguarde 20 segundos e consulte a linha novamente.

```
get 'ttl_exemplo', 'linha123', 'cf:desc'
```

# Comandos do Cassandra

## Criação do keyspace (schema, namespace)

```
CREATE KEYSPACE empresa  
WITH replication = {'class': 'SimpleStrategy', 'replication_factor' : 3};
```

## Criação de tabela

```
create table empresa.funcionario  
(  
    empregadoid int primary key,  
    empregadonome text,  
    empregadocargo text,  
);
```

## Criação de índice secundário para consulta

```
CREATE INDEX empresacargo ON empresa.funcionario (empregadocargo);
```



# Cont. Comandos do Cassandra

```
cqlsh:empresa> help

Documented shell commands:
=====
CAPTURE      COPY  DESCRIBE  EXPAND  LOGIN  SERIAL  SOURCE
CONSISTENCY  DESC  EXIT      HELP    PAGING SHOW    TRACING

CQL help topics:
=====
ALTER                  CREATE_TABLE_OPTIONS  SELECT
ALTER_ADD              CREATE_TABLE_TYPES    SELECT_COLUMNFAMILY
ALTER_ALTER            CREATE_USER            SELECT_EXPR
ALTER_DROP             DELETE                 SELECT_LIMIT
ALTER_RENAME           DELETE_COLUMNS         SELECT_TABLE
ALTER_USER             DELETE_USING           SELECT_WHERE
ALTER_WITH             DELETE_WHERE           TEXT_OUTPUT
APPLY                 DROP                  TIMESTAMP_INPUT
ASCII_OUTPUT           DROP_COLUMNFAMILY     TIMESTAMP_OUTPUT
BEGIN                 DROP_INDEX            TRUNCATE
BLOB_INPUT            DROP_KEYSPACE         TYPES
BOOLEAN_INPUT         DROP_TABLE            UPDATE
COMPOUND_PRIMARY_KEYS DROP_USER              UPDATE_COUNTERS
CREATE                GRANT                 UPDATE_SET
CREATE_COLUMNFAMILY   INSERT                UPDATE_USING
CREATE_COLUMNFAMILY_OPTIONS  LIST                  UPDATE_WHERE
CREATE_COLUMNFAMILY_TYPES  LIST_PERMISSIONS     USE
CREATE_INDEX          LIST_USERS            UUID_INPUT
CREATE_KEYSPACE       PERMISSIONS
CREATE_TABLE          REVOKE
```

cqlsh:empresa> █

# Exercício

**1. Criar uma tabela que representa lista de Cidades e que permite armazenar até 5 versões na Column Family com os seguintes campos:**

Código da cidade como rowKey

Column Family=info

Nome da Cidade

Data de Fundação

Column Family=responsaveis

Nome Prefeito

Data de Posse do Prefeito

Nome Vice prefeito

Column Family=estatisticas

Data da última Eleição

Quantidade de moradores

Quantidade de eleitores

Ano de fundação

# Exercício

2. Inserir 10 cidades na tabela criada de cidades.
3. Realizar uma contagem de linhas na tabela.
4. Consultar só o código e nome da cidade.
5. Escolha uma cidade, consulte os dados dessa cidade em específico antes do próximo passo.
6. Altere para a cidade escolhida os dados de Prefeito, Vice Prefeito e nova data de Posse.
7. Consulte os dados da cidade alterada.
8. Consulte todas as versões dos dados da cidade alterada.



# Exercício

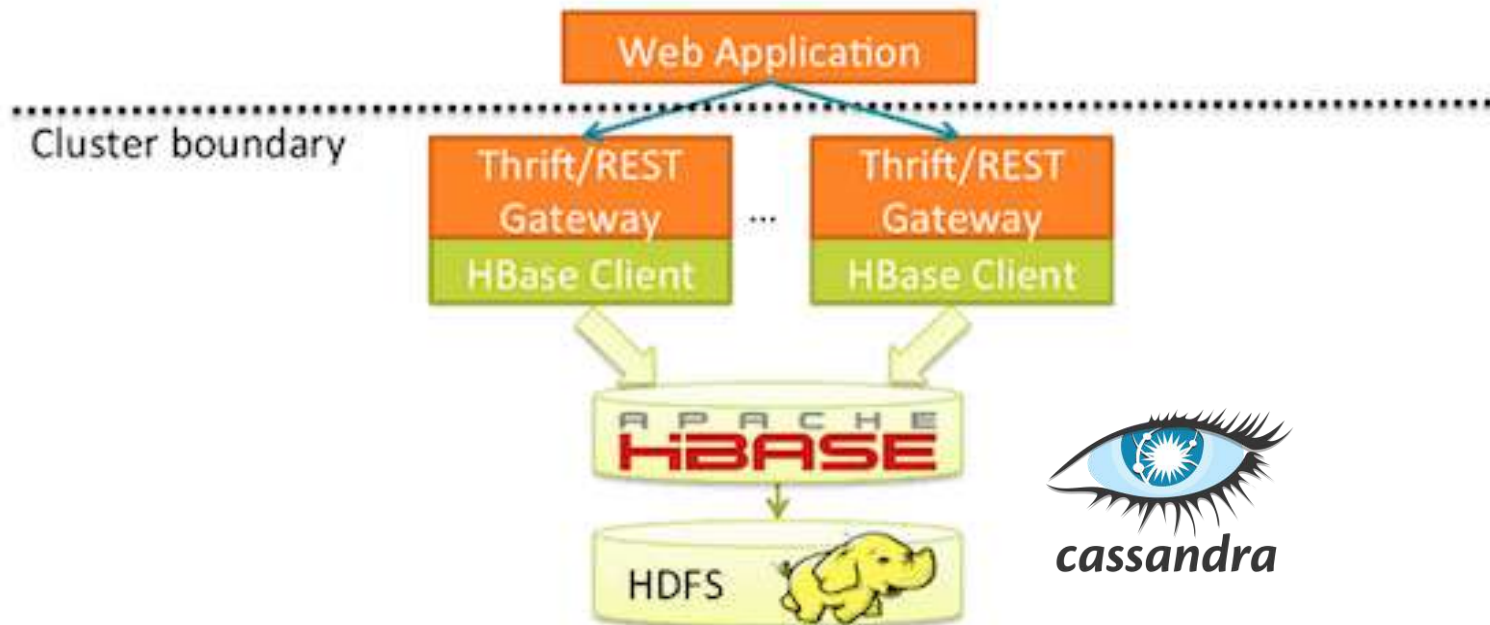
9. Exclua as três cidades com menor quantidade de habitantes e quantidade de eleitores.
10. Liste todas as cidades novamente.
11. Adicione na ColumnFamily “estatísticas”, duas novas colunas de “quantidade de partidos políticos” e “Valor em Reais à partidos” para as 2 cidades mais populosas cadastradas.
12. Liste novamente todas as cidades.

# 4. Cenários de Utilização

## NoSQL com Hbase e Cassandra

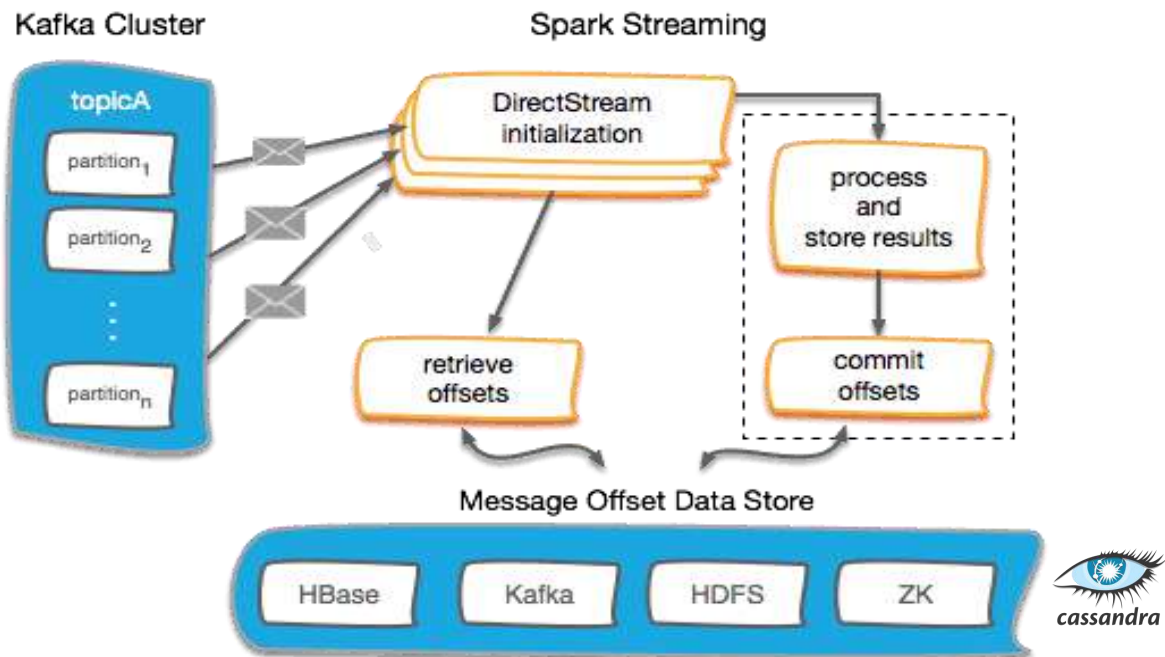
# Cenário 1 de Utilização

Utilizado como banco de dados para aplicações Web e aplicativos móveis.  
Por meio de integrações REST é possível fazer essa integração com o HBase.




# Cenário 2 de Utilização

Utilizado como repositório para guardar uma cópia e/ou replicador dos dados vindo de serviços de eventos antes da consolidação final.



# Cenário 3 de Utilização

Enriquecimento dos dados finais com dados armazenados no HBase. Por exemplo: lookups. Como há o versionamento padrão do Hbase, é possível ter o rastro das informações alteradas para cada rowKey.



# 5. Operações massivas

## NoSQL com Hbase e Cassandra

# O que é *Build Insert*?

Nos banco de dados essa é a uma operação que permite fazer a carga massiva de dados.

Normalmente isso ocorre por acionamento de um programa utilitário do banco de dados.

No HBase é possível realizar essa carga por esses meios mais comuns:

- Classe Utilitária do HBase [`org.apache.hadoop.hbase.mapreduce.ImportTsv`].
- Intermediários em script com Sqoop, aplicações em Spark, Apache Phoenix, e etc, que implementam indiretamente a Hbase API.
- External Table do Hive utilizando `StorageHandler` para gravar os dados no Hbase/Cassandra.
- API

# Exemplo de Bulk Insert

1. Confirmar que o arquivo `employees.csv` esteja em `/home/everis/arquivos/employee.csv`
2. Criar a tabela `employees` no Hbase com a column Family: `employee_data`

3. Criar uma pasta no HDFS pelo shell do Linux

```
hadoop fs -mkdir /test
```

Copia os arquivos exportados para o HDFS pelo shell do Linux

```
hadoop fs -copyFromLocal /home/everis/arquivos/employees.csv /test/employees.csv
```

4. Executar a importação no shell do Linux

```
hbase org.apache.hadoop.hbase.mapreduce.ImportTsv -Dimporttsv.separator=';' -  
Dimporttsv.columns=HBASE_ROW_KEY,employee_data:birth_date,employee_data:first_name,e  
mployee_data:last_name,employee_data:gender,employee_data:hire_date employees  
/test/employees.csv
```



# Exercício

1. Criar a tabela salaries no HBASE com o schema ao lado.
2. Efetuar a carga de dados via ImportTsv utilizando o arquivo salaries.csv
3. Verificar a quantidade na tabela carregada versus a quantidade de linhas do arquivo.
4. Crie a tabela salaries\_concatenado agora para o arquivo salaries\_com\_row\_key.csv, observe que esse arquivo tem uma coluna a mais que é a row\_key concatenada.
5. Porque o primeiro arquivos carregou menos registros?

```
mysql> select * from salaries limit 10;
```

emp_no	salary	from_date	to_date
10001	60117	1986-06-26	1987-06-26
10001	62102	1987-06-26	1988-06-25
10001	66074	1988-06-25	1989-06-25
10001	66596	1989-06-25	1990-06-25
10001	66961	1990-06-25	1991-06-25
10001	71046	1991-06-25	1992-06-24
10001	74333	1992-06-24	1993-06-24
10001	75286	1993-06-24	1994-06-24
10001	75994	1994-06-24	1995-06-24
10001	76884	1995-06-24	1996-06-23

```
10 rows in set (0.00 sec)
```

# 6. Integrações NoSQL com Ambiente Hadoop

NoSQL com Hbase e Cassandra

# Integração NoSQL com Hadoop

É possível realizar essa integração utilizando a implementação da interface **StorageHandler** com a classe **org.apache.hadoop.hive.hbase.HBaseStorageHandler** que o Hbase disponibiliza.

No Hive a interface **StorageHandler** permite que outras aplicações externas ao Hive (i.e Cassandra, Azure Table, JDBC (MySQL), MongoDB, ElasticSearch, e etc) implementem e disponibilizem operações dessas estruturas e dados armazenados ao Apache Hive.

A idéia é que o Hive tenha visibilidade do metadados quando a tabela é criado no Hive mas os dados e o controle de armazenamento esteja externo.

É uma evolução do conceito de tabela gerenciada (managed) e externa (external) do Hive.

Saber mais sobre StorageHandlers, [saiba mais](#).

Para saber mais detalhes da Integração do Hive e HBase e quais operações estão suportadas, [saiba mais](#).



# Exemplo Integração NoSQL com Hadoop

Utilizando a tabela employee utilizada nos exercícios anteriores, vamos dar visibilidade ao Hive dessa estrutura do HBase.

## 1. Vamos criar um novo schema no Hive.

```
CREATE DATABASE tabelas_hbases;
```

## 2. Criar a tabela employee no Hive.

```
CREATE EXTERNAL TABLE tabelas_hbases.employees (  
  emp_no INT,  
  birth_date string,  
  first_name string,  
  last_name string,  
  gender string,  
  hire_date string)  
STORED BY 'org.apache.hadoop.hive.hbase.HBaseStorageHandler'  
WITH SERDEPROPERTIES("hbase.columns.mapping"=":key, employee_data:birth_date,  
  employee_data:first_name, employee_data:last_name, employee_data:gender, employee_data:hire_date")  
TBLPROPERTIES("hbase.table.name"="employees", "hbase.mapred.output.outputtable"="employees");
```

# Exercício

- 1. Criar a tabela externa salaries no Hive que representa a mesma tabela que foi carregada em exercícios anteriores no Hbase.**
- 2. Consultar os empregados com o maior salário em cada ano.**
- 3. Consultar o quanto foi gasto em salários por ano.**

# 7. Próximos passos

NoSQL com Hbase e Cassandra

# Próximos Passos

Utilizar o **Apache Spark** para processamento distribuído de informações vindo de eventos (Kafka) ou gravando em tópicos com as informações de dados no **Hbase/Cassandra**.  
Resumindo: olhar para Arquitetura de Eventos no big data.

Aplicação **Apache Phoenix** que habilita capacidades de execução consultas SQL, analítico e OLTP ao HBase.

As duas distribuições mais conhecidas do ecossistema do Hadoop on-premise Cloudera e Horton suportam e em algumas instalações podem permitir a utilização ou já utilizam.

<https://phoenix.apache.org/> e [https://phoenix.apache.org/who\\_is\\_using.html](https://phoenix.apache.org/who_is_using.html)

Caso queira aprofundar o conhecimento em NoSQL, olhar outros produtos como **Apache Cassandra (versão da DATASTAX)** <https://www.datastax.com/> que tem versão do Cassandra as a Service.

# Referências Utilizadas

NoSQL com Hbase e Cassandra



# Referências e Bibliografia

[Apache HBase Reference Guide](#)

[Secondary Indexing on Hbase](#)


[Cloudera Apache HBase Rest Interface](#)

[Hbase as Offset Managment for Apache Kafka with Apache Spark Streaming](#)

[Ccomo-se-aplica-el-teorema-cap-y-el-reto-de-la-escalabilidad-en-las-rdbms-y-nosql](#)

[NoSQL do teorema CAP para PACCL](#)

[Apache Cassandra 3.x Reference Guide](#)



# Dúvidas?

[Nome do curso]